

Matemática del ajuste en *Mossbauer*

Modos discreto y de distribución, con propuestas de mejora

Análisis del código en rama `main`

27 de mayo de 2026

Resumen

Este documento describe formalmente el problema de optimización que resuelve la aplicación *Mossbauer* cuando ajusta un espectro de transmisión: (i) en modo *discreto* (suma finita de sextetes/dobletes/singletes) y (ii) en modo *distribución* (densidad continua $P(B_{\text{hf}})$ o $P(\Delta E_Q)$ regularizada). Se detallan el modelo directo, el funcional de coste, el algoritmo de minimización, el cálculo de incertidumbres y los diagnósticos estadísticos, con referencias precisas a los ficheros y líneas del código actual. Al final de cada sección, y en una sección dedicada, se proponen mejoras concretas y aplicables.

Índice

1. Modelo directo	2
1.1. Forma de línea	2
1.2. Sextete (interacción magnética)	2
1.3. Doblete y singlete (<code>core/physics.py:45-61</code>)	2
2. Ajuste discreto	3
2.1. Parámetros activos y restricciones	3
2.2. Pesos y residuo	3
2.3. Optimizador	3
2.4. Covarianza y errores 1σ	4
2.5. Diagnósticos estadísticos (<code>...:3207-3251</code>)	4
2.6. Bootstrap paramétrico (<code>...:3488-3547</code>)	4
3. Ajuste con distribución $P(B_{\text{hf}})$ o $P(\Delta E_Q)$	4
3.1. Discretización	4
3.2. Matriz núcleo K (<code>...:78-107, 149-211</code>)	4
3.3. Sistema lineal aumentado (<code>...:392-445</code>)	5
3.4. Distribuciones paramétricas	5
3.5. Refinamiento global (esquema VARPRO simplificado)	5
3.6. Escaneo de α y curva L (<code>...:3609-3722</code>)	6
3.7. Estadísticos para el modo distribución (<code>...:3958-3963</code>)	6
4. Propuestas de mejora	6
5. Resumen visual de la pila de optimización	8
6. Conclusión	8

1. Modelo directo

El espectro pliega los datos brutos a N canales con velocidades $\{v_i\}_{i=1}^N$ y transmisión normalizada $\{y_i\}$, $y_i \approx 1$ fuera de los picos de absorción. El modelo es

$$T(v; \boldsymbol{\theta}) = b + s v - \sum_{c=1}^{N_c} A_c(v; \boldsymbol{\theta}_c) \quad (1)$$

con *baseline* b y pendiente s *multiplicativos* (los datos ya están normalizados por `norm_factor`). Esto es un modelo de absorbente *delgado* (lineal en la profundidad), ver `core/physics.py:74-87`.

1.1. Forma de línea

La función `line_profile` (`core/physics.py:14-21`) selecciona globalmente Lorentziana o pseudo-Voigt:

$$L(v; v_0, \gamma) = \frac{\gamma^2}{(v - v_0)^2 + \gamma^2}, \quad (2)$$

$$V(v; v_0, \gamma, \sigma) = \frac{1}{c_V} \Re \left[\frac{w\left(\frac{(v-v_0)+i\gamma}{\sigma\sqrt{2}}\right)}{\sigma\sqrt{2\pi}} \right], \quad c_V = \max_v(\cdot), \quad (3)$$

con $w(z) = \exp(-z^2) \operatorname{erfc}(-iz)$ (función de Faddeeva). El factor c_V *normaliza el pico a 1* dividiendo por el máximo discreto del muestreo, lo cual es funcional pero pierde interpretabilidad analítica (véase mejora 4).

1.2. Sextete (interacción magnética)

Las seis posiciones de línea (`core/physics.py:38`, constantes en `core/constants.py:21,25,28,29`) se obtienen escalando la referencia a 33 T y desplazándolas por δ y ΔE_Q :

$$v_{0,j} = \frac{B_{\text{hf}}}{33} r_j^{(33)} + \delta + s_j \Delta E_Q, \quad j = 1, \dots, 6, \quad (4)$$

con $r^{(33)} = \frac{1}{2} [-10,657, -6,167, -1,677, 1,677, 6,167, 10,657]$ y

$$\mathbf{s} = [+ \frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, + \frac{1}{2}]. \quad (5)$$

Las anchuras (HWHM) son $\gamma_j = \gamma_1 \cdot [1, \gamma_2, \gamma_3, \gamma_3, \gamma_2, 1]_j$ (con γ_2, γ_3 *relativas*), y las amplitudes

$$W_j = [I_1, I_2, I_3, I_3, I_2, I_1]_j, \quad I_1 = i_3 i_1, I_2 = i_3 i_2, I_3 = i_3, \quad (6)$$

con i_1, i_2, i_3 libres (no se impone la relación 3:2:1, véase mejora 4). La absorción del componente es

$$A_{\text{sext}}(v) = d \sum_{j=1}^6 W_j L(v; v_{0,j}, \gamma_j), \quad (7)$$

donde d es la profundidad. La ecuación (4) es un tratamiento *de primer orden* de la interacción magnética: ΔE_Q entra como un patrón rígido aditivo, sin diagonalización del Hamiltoniano combinado $\mathcal{H} = \mathcal{H}_M + \mathcal{H}_Q$ (válido para $\Delta E_Q \ll \mu_N g B_{\text{hf}}$).

1.3. Doblete y singlete (`core/physics.py:45-61`)

$$A_{\text{dob}}(v) = d [i_1 L(v; \delta - \frac{\Delta E_Q}{2}, \gamma_1) + i_1 i_2 L(v; \delta + \frac{\Delta E_Q}{2}, \gamma_1 \gamma_2)], \quad (8)$$

$$A_{\text{sing}}(v) = d i_1 L(v; \delta, \gamma_1). \quad (9)$$

2. Ajuste discreto

2.1. Parámetros activos y restricciones

El vector $\mathbf{x} \in \mathbb{R}^p$ contiene los parámetros *libres*: globales $\{b, s, v_{\text{máx}}, c_{\text{fold}}\}$ y por componente $\theta_c = (\delta, \Delta E_Q, B_{\text{hf}}, \gamma_1, \gamma_2, \gamma_3, d, i_1, i_2, i_3)$ filtrados por (mossbauer_fe33_gui_v2IA.py:3050-3055, 3341-3376):

- *Habilitados* sextet_enabled[c];
- *Fijos* fixed_vars[k] se eliminan del vector activo;
- *Restringidos lineales* $k_t = \alpha k_s + \beta$ se aplican *en cada evaluación* (hasta seis iteraciones para cadenas), ...:2841-2872.

Los *bounds* duros (...:3266-3282) son, por ejemplo, $b \in [0,7, 1,3]$, $s \in [-10^{-4}, 10^{-4}]$, $\delta \in [-2, 3]$, $\Delta E_Q \in [0, 4]$, $B_{\text{hf}} \in [0, 50]$ T, $\gamma_1 \in [0,03, 2]$, $d \in [0, 0,30]$.

2.2. Pesos y residuo

La incertidumbre por canal viene del plegado de dos canales Poisson:

$$\sigma_i = \frac{\text{máx}(\sqrt{c_i/2}, 1)}{f_{\text{norm}}}, \quad \sigma_i \leftarrow \text{máx}(\sigma_i, 10^{-9}), \quad (10)$$

donde c_i es el conteo plegado y f_{norm} el factor de normalización (...:3171-3181). El residuo ponderado, vector de dimensión N , es

$$r_i(\mathbf{x}) = \frac{T(v_i; \mathbf{x}) - y_i}{\sigma_i}. \quad (11)$$

El funcional de coste es

$$\mathcal{C}(\mathbf{x}) = \frac{1}{2} \|\mathbf{r}(\mathbf{x})\|_2^2 \equiv \frac{1}{2} \chi^2(\mathbf{x}). \quad (12)$$

2.3. Optimizador

Se invoca `scipy.optimize.least_squares` con método *Trust Region Reflective* (TRF), Jacobiano por diferencias finitas (2-point), pérdida lineal, `max_nfev=7000` (...:3433):

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in [\ell, \mathbf{u}]} \frac{1}{2} \|\mathbf{r}(\mathbf{x})\|^2. \quad (13)$$

TRF resuelve en cada iteración el subproblema cuadrático

$$\min_{\mathbf{d}} \frac{1}{2} \|J_k \mathbf{d} + \mathbf{r}_k\|^2 \quad \text{s.t.} \quad \|\mathbf{D}_k \mathbf{d}\| \leq \Delta_k, \quad \ell - \mathbf{x}_k \leq \mathbf{d} \leq \mathbf{u} - \mathbf{x}_k, \quad (14)$$

con escalado adaptativo $\mathbf{D}_k$ y reflexión en los bordes activos.

Multistart. Se realizan 8 reinicios gaussianos en torno al usuario (...:3407-3422):

$$\mathbf{x}^{(s)} = \mathbf{x}^{(0)} + \boldsymbol{\xi}^{(s)}, \quad \xi_k^{(s)} \sim \mathcal{N}(0, \sigma_k^2), \quad \sigma_k = \rho_k(\mathbf{u}_k - \ell_k), \quad (15)$$

con $\rho_k = 0,12$ para $\{\delta, \Delta E_Q, B_{\text{hf}}, \gamma_1, d, v_{\text{máx}}\}$ y $\rho_k = 0,08$ para el resto; semilla fija 12345. Se retiene el de menor $\mathcal{C}$.

2.4. Covarianza y errores 1σ

A partir del Jacobiano final $J = U\Sigma V^\top$ (SVD) y truncando Σ_{kk} por debajo de un umbral (...:3451-3468):

$$\widehat{\text{Cov}}(\hat{\mathbf{x}}) = V \Sigma^{-2} V^\top \cdot \frac{2\mathcal{C}(\hat{\mathbf{x}})}{N-p}, \quad \hat{\sigma}_{x_k} = \sqrt{\widehat{\text{Cov}}_{kk}}. \quad (16)$$

Esta es la covarianza MLE Gaussiana usando el χ^2_{red} de los residuos ya normalizados por σ_i . Se reportan correlaciones $|\rho_{kl}| \geq 0,95$ (...:3194-3205).

2.5. Diagnósticos estadísticos (...:3207-3251)

Con N datos y p libres,

$$\chi^2 = \sum_i r_i^2, \quad \nu = N - p, \quad \chi^2_\nu = \chi^2/\nu, \quad (17)$$

$$\text{AIC} = N \ln(\text{RSS}/N) + 2p, \quad \text{BIC} = N \ln(\text{RSS}/N) + p \ln N, \quad (18)$$

$$\rho_1 = \frac{\sum_i \tilde{r}_i \tilde{r}_{i+1}}{\sum_i \tilde{r}_i^2}, \quad Z_{\text{runs}} = \frac{R - \mu_R}{\sigma_R} \text{ (Wald-Wolfowitz)}, \quad (19)$$

$$c_{\text{antisim}} = \frac{\mathbf{r} \cdot (-\mathbf{r}^{\text{rev}})}{\mathbf{r} \cdot \mathbf{r}} \quad (\text{detector de error de centrado}). \quad (20)$$

Se levanta aviso si $|\rho_1| > 0,35$, $|Z| > 2$ o $c_{\text{antisim}} > 0,45$.

2.6. Bootstrap paramétrico (...:3488-3547)

$M \in [5, 300]$ replicas: $\tilde{y}^{(m)} = T(\cdot; \hat{\mathbf{x}}) + \eta^{(m)}$, $\eta_i^{(m)} \sim \mathcal{N}(0, \sigma_i^2)$; se reajusta a $\mathbf{x}_0$ y se calcula $\hat{\sigma}_{x_k}^{\text{boot}} = \text{std}_m(\hat{x}_k^{(m)})$, que reemplaza la $\hat{\sigma}$ de (16).

3. Ajuste con distribución $P(B_{\text{hf}})$ o $P(\Delta E_Q)$

3.1. Discretización

Se elige $B_{\text{hf}} \in [B_{\text{mín}}, B_{\text{máx}}]$ (o $\Delta E_Q \in [\Delta_{\text{mín}}, \Delta_{\text{máx}}]$) con n bins de centros equiespaciados (mossbauer_distribution.py:133-146):

$$\mathbf{c} \in \mathbb{R}^n, \quad c_k = B_{\text{mín}} + (k - \tfrac{1}{2})h, \quad h = \frac{B_{\text{máx}} - B_{\text{mín}}}{n}. \quad (21)$$

3.2. Matriz núcleo K (...:78-107, 149-211)

Para variable = B_{hf} se construye

$$K_{ik} = A_{\text{sext}}^{(d=1)}(v_i; B_{\text{hf}} = c_k, \delta = \delta_g, \Delta E_Q = \Delta E_{Qg}, \gamma), \quad (22)$$

es decir, la absorción a velocidad v_i producida por un sextete de *profundidad unitaria* con $B_{\text{hf}} = c_k$. Análogamente para variable = ΔE_Q se fija B_{hf} y se barre ΔE_Q . **Nota importante:** en el núcleo de la distribución se impone $I_1:I_2:I_3 = 3:2:1$ de forma estructural (...:97-99), a diferencia del modo discreto donde los i_k son libres. Esto se compensa en el constructor del componente "sharp" (mossbauer_fe33_gui_v2IA.py:3725-3766).

3.3. Sistema lineal aumentado (...:392-445)

Sea $\mathbf{p} \in \mathbb{R}^n$ el vector de pesos de la distribución, b el *baseline* y s la pendiente. El forward es

$$\hat{y}_i = b + s v_i - \sum_{k=1}^n K_{ik} p_k - \sum_{m=1}^{M_s} K_{im}^{(\text{sharp})} q_m, \quad (23)$$

donde $q_m \geq 0$ son las amplitudes de hasta M_s sextetes nítidos opcionales. Definiendo

$$X = [\mathbf{1} \mid \mathbf{v} \mid -K \mid -K^{(\text{sharp})}] \in \mathbb{R}^{N \times (2+n+M_s)},$$

con *bounds* $[0, \infty)$ en columnas 1, 3, ..., $2+n+M_s$ y $(-\infty, \infty)$ en columna 2 (pendiente), el problema regularizado es

$$\min_{\mathbf{z} \geq \mathbf{0} \text{ (salvo } s)} \|W^{1/2}(X\mathbf{z} - \mathbf{y})\|_2^2 + \alpha \|L\mathbf{p}\|_2^2, \quad \mathbf{z} = (b, s, \mathbf{p}^\top, \mathbf{q}^\top)^\top. \quad (24)$$

Aquí $W = \text{diag}(1/\sigma_i^2)$ (igual que en (10)) y $L \in \mathbb{R}^{(n-2) \times n}$ es el operador *segunda diferencia* (...:214-224):

$$L = \begin{pmatrix} 1 & -2 & 1 & 0 & \cdots & 0 \\ 0 & 1 & -2 & 1 & \cdots & 0 \\ \vdots & & \ddots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & 1 & -2 & 1 \end{pmatrix}, \quad (25)$$

de forma que $\|L\mathbf{p}\|^2 = \sum_k (p_{k-1} - 2p_k + p_{k+1})^2$ penaliza curvatura.

Implementación. Se apila $\begin{bmatrix} W^{1/2}X \\ \sqrt{\alpha} L_{\text{ext}} \end{bmatrix} \mathbf{z} = \begin{bmatrix} W^{1/2}\mathbf{y} \\ \mathbf{0} \end{bmatrix}$ con L_{ext} extendido con ceros en las columnas de b, s, q , y se resuelve con `scipy.optimize.lsqr_linear(bounds, lsqr_tol="auto", max_iter=2000)` (...:444). La *normalización* $\sum_k p_k h = 1$ se aplica *a posteriori* (...:227-236), no como restricción dura.

Existe una variante NNLS pura para fondo fijo (...:747-785) basada en `scipy.optimize.nnls`.

3.4. Distribuciones paramétricas

En lugar del Tikhonov no paramétrico se puede usar

$$p_k^{\text{Gauss}} = A \exp\left(-\frac{1}{2}\left(\frac{c_k - \mu}{\varsigma}\right)^2\right), \quad \text{libres } (b, s, A, \mu, \log \varsigma), \quad (26)$$

$$p_k^{\text{Bin}} \propto \binom{n-1}{k-1} p^{k-1} (1-p)^{n-k}, \quad \text{libres } (b, s, A, \logit p), \quad (27)$$

$$p_k^{\text{Fija}} = \phi_k \text{ (precargada)}, \quad \text{libres } (b, s, A, \mathbf{q}). \quad (28)$$

En todos los casos los $\mathbf{q} \geq 0$ de sextetes nítidos se ajustan a la vez por mínimos cuadrados no lineales (Gauss, binomial) o lineales acotados (fija).

3.5. Refinamiento global (esquema VARPRO simplificado)

Cuando *refine_global* está activo (`mossbauer_fe33_gui_v2IA.py:3858-3945`), se introduce un bucle externo no lineal sobre $\boldsymbol{\eta} = (\delta_g, \log \gamma_g, \{\delta_m, \Delta E_{Qm}, B_{\text{hfm}}, \log \gamma_{1,m}\}_{m=1}^{M_s})$. En cada evaluación del externo se recompone $K(\boldsymbol{\eta})$ y se resuelve *íntegramente* el problema interno (24) (o el paramétrico), devolviendo el residuo a `least_squares`:

$$\min_{\boldsymbol{\eta}} \|W^{1/2}[X(\boldsymbol{\eta}) \hat{\mathbf{z}}(\boldsymbol{\eta}) - \mathbf{y}]\|^2, \quad \hat{\mathbf{z}}(\boldsymbol{\eta}) = \arg \min_{\mathbf{z}} (24). \quad (29)$$

Es una formulación tipo *separable least squares* (Golub–Pereyra). En el código: `max_nfev=60`, Jacobiano por diferencias finitas a través del solver acotado interno; sin Jacobiano analítico y sin *warm-start*.

3.6. Escaneo de α y curva L (...:3609-3722)

Se evalúa el problema interno para $\alpha \in \{\alpha_k\}_{k=1}^{31}$, $\log_{10} \alpha_k \in [-8, 4]$ equiespaciados. Definiendo $\rho(\alpha) = \log \|W^{1/2}(X\hat{z} - y)\|$, $\eta(\alpha) = \log \|L\hat{p}\|$, la *esquina* de la curva L se localiza por máxima curvatura

$$\kappa(\alpha) = \frac{\rho'\eta'' - \eta'\rho''}{((\rho')^2 + (\eta')^2)^{3/2}}, \quad \hat{\alpha}_L = \alpha \quad \kappa(\alpha), \quad (30)$$

calculada por diferencias centrales sobre la malla logarítmica de 31 puntos (...:3575-3591). Se reporta además un $\hat{\alpha}_{\text{comp}}$ por mínima distancia normalizada al origen en el plano (η, ρ) (...:3593-3607).

3.7. Estadísticos para el modo distribución (...:3958-3963)

χ^2 y χ_ν^2 se computan como en el discreto, con $p_{\text{eff}} = n + \mathbf{1}_{\text{fit } b} + \mathbf{1}_{\text{fit } s} + M_s + |\boldsymbol{\eta}|$. Este conteo *sobrestima* los grados de libertad efectivos del problema regularizado (ver mejora 4).

4. Propuestas de mejora

A continuación se enumeran cambios concretos, ordenados por impacto esperado en la calidad del ajuste y la honestidad estadística.

Mejora: Likelihood Poisson en lugar de χ^2 Gaussiano

Las cuentas son Poisson; la aproximación $\sigma_i = \sqrt{c_i/2}$ se rompe en canales de bajo conteo (cola del espectro, escalado por absorbentes gruesos). Sustituir (11) por $r_i = 2(\sqrt{c_i + 3/8} - \sqrt{\hat{c}_i + 3/8})$ (Anscombe, varianza unidad) o, en plena máxima verosimilitud, $-2 \log \mathcal{L} = 2 \sum_i [\hat{c}_i - c_i + c_i \log(c_i/\hat{c}_i)]$, válida para $c_i \geq 0$.

Mejora: Grados de libertad efectivos en Tikhonov

En (24) no todos los n bins son grados de libertad reales. Usar $p_{\text{eff}} = \text{tr}(A(\alpha))$, $A(\alpha) = X(X^\top W X + \alpha L^\top L)^{-1} X^\top W$, y redefinir $\chi_\nu^2 = \chi^2/(N - p_{\text{eff}})$. Sin esto el χ_ν^2 reportado en modo distribución es siempre demasiado pesimista o demasiado optimista.

Mejora: Selección automática de α por GCV o discrepancia

La curvatura (30) en una malla de 31 puntos es *ruidosa*. Más estables:

$$\text{GCV}(\alpha) = \frac{\|W^{1/2}(I - A(\alpha))\mathbf{y}\|^2}{[\text{tr}(I - A(\alpha))]^2} \quad (\text{sin parámetros adicionales}),$$

Morozov: elegir α tal que $\chi^2(\hat{z}(\alpha)) \approx N - p_{\text{eff}}$.

GCV en particular no requiere conocer σ y es óptimo en pérdida de predicción.

Mejora: Refinamiento global con Jacobiano analítico (VARPRO)

En (29) se evalúa el solver interno para cada perturbación finita. El Jacobiano analítico de Golub–Pereyra usa $\partial \hat{z} / \partial \eta_j = -(X^\top W X + \alpha L^\top L)^{-1} (\partial X^\top W / \partial \eta_j) (X\hat{z} - y)$, restringido al *conjunto activo* de bounds. Esto, junto con *warm-start* de `lsq_linear`, multiplica $\times 5$ – 10 la velocidad del modo `refine_global` y aumenta `max_nfev` efectivamente.

Mejora: Regularización TV / MaxEnt

La penalización $\|L\mathbf{p}\|_2^2$ favorece distribuciones suaves. Para distribuciones con picos bien definidos (mezcla de fases), usar

$$\alpha \|D_1\mathbf{p}\|_1 \quad (\text{Total Variation, vía ADMM o PDHG}), \quad \text{o} \quad \alpha \sum_k p_k \log \frac{p_k}{m_k} \quad (\text{MaxEnt}),$$

ambos compatibles con $\mathbf{p} \geq \mathbf{0}$.

Mejora: Razón 3:2:1 explícita en el modo discreto

El kernel de la distribución impone $I_1:I_2:I_3 = 3:2:1$ (`mossbauer_distribution.py:97-99`), pero el modo discreto deja libres i_1, i_2, i_3 . Añadir una restricción opcional $i_1 = 3, i_2 = 2, i_3$ libre (`depth`) — o expuesta como parámetro de textura f : $(I_1, I_2, I_3) = (3, 2, 1)(1 + f\mathbf{t})$ — daría comparabilidad directa entre modos y reduce p en ~ 2 por sextete.

Mejora: Normalización analítica del Voigt

En (3) $c_V = \text{máx}$ es discreto, ruidoso y depende del muestreo. Usar $c_V = \Re w(i\gamma/(\sigma\sqrt{2})) / (\sigma\sqrt{2\pi})$ (valor analítico en $v = v_0$). Hace `depth` comparable entre Lorentz y Voigt.

Mejora: Hamiltoniano completo magnético + cuadrupolar

La ecuación (4) sólo trata ΔE_Q a primer orden. Para ΔE_Q no pequeños (Fe_3O_4 a baja T , sitios con simetría baja) y ángulo β entre eje magnético y EFG, las seis posiciones se obtienen diagonalizando 4×4 (estado fundamental) más mezcla del excitado. Implementación cerrada por la solución exacta de Kündig o por diagonalización numérica.

Mejora: Integral de transmisión de absorbente grueso

(1) es lineal en absorbedor. Para $t \gtrsim 1$ usar $T(v) = 1 - f_a[1 - \exp(-t_a \Sigma_c A_c)]$ o la integral de Margulies–Ehrman convolucionada con la línea de fuente. Añadir un parámetro de espesor efectivo t_a corrige sesgos sistemáticos en d y γ .

Mejora: Pérdida robusta para espurios

Pasar `least_squares(..., loss="huber", f_scale=3)` reduce la influencia de canales con picos cósmicos o errores de plegado en $\hat{\mathbf{x}}$, sin cambiar el resultado en regiones limpias.

Mejora: Barras de error en $P(B_{\text{hf}})$

Actualmente no se reporta incertidumbre en la distribución. En el conjunto activo (índices $\mathcal{A} = \{k : \hat{p}_k > 0\}$),

$$\widehat{\text{Cov}}(\hat{\mathbf{p}}_{\mathcal{A}}) = (X_{\mathcal{A}}^{\top} W X_{\mathcal{A}} + \alpha L_{\mathcal{A}}^{\top} L_{\mathcal{A}})^{-1} X_{\mathcal{A}}^{\top} W X_{\mathcal{A}} (X_{\mathcal{A}}^{\top} W X_{\mathcal{A}} + \alpha L_{\mathcal{A}}^{\top} L_{\mathcal{A}})^{-1},$$

de coste despreciable. Alternativa: extender el bootstrap paramétrico (`...`:3488-3547) al modo distribución.

Mejora: Propagación de incertidumbre de calibración

$v_{\text{máx}}$ se ajusta opcionalmente pero $\sigma_{v_{\text{máx}}}$ no entra en σ_i . Añadir $\sigma_i^2 \leftarrow \sigma_i^2 + (\partial T / \partial v_{\text{máx}})^2 \sigma_{v_{\text{máx}}}^2$ corrige el sesgo en δ típico de calibraciones imperfectas.

Mejora: Condicionamiento de K para B_{hf} pequeño

Para $B_{\text{hf}} \rightarrow 0$ las seis líneas colapsan al centro y las columnas correspondientes de K se vuelven casi colineales con un singlete. Esto produce $P(B_{\text{hf}})$ artefactuosa en $B \lesssim 2\text{ T}$. Sugerencias: (i) imponer $B_{\text{min}} \gtrsim 2\text{ T}$ por defecto en modo B_{hf} , (ii) reescalar columnas $K_{:,k} \leftarrow K_{:,k}/\|K_{:,k}\|$ antes del solver y deshacer el escalado al final, (iii) añadir una columna explícita de singlete/doblete y dejar que el optimizador decida.

Mejora: Optimización global en el discreto

Con ≥ 2 sextetes, hay mínimos locales por permutación de etiquetas y por intercambio $B_{\text{hf}1} \leftrightarrow B_{\text{hf}2}$. Antes del TRF, un `differential_evolution` con presupuesto de ~ 200 evaluaciones, seguido de pulido TRF, mejora notablemente la robustez. La estructura multistart actual (8 perturbaciones gaussianas con semilla fija) no cubre saltos de etiquetado.

Mejora: Warm-start del conjunto activo en el escaneo de α

En $\dots:3624\text{--}3647$ cada α_k se resuelve desde cero. `lsq_linear` admite reusar el conjunto activo del α_{k-1} (similares por ser logarítmicamente cercanos); típicamente reduce $\times 4\text{--}6$ el tiempo de la curva L.

Mejora: Ampliar bounds de la pendiente

$s \in [-10^{-4}, 10^{-4}]$ ($\dots:3270$) es restrictivo si el detector tiene deriva ($\sim 10^{-3}/\text{mm}\cdot\text{s}^{-1}$). Ampliar a $\pm 5 \cdot 10^{-3}$ y dejar que χ^2 ponderado decida (la pendiente ya está penalizada por la baseline si se eliminan sesgos por bordes).

5. Resumen visual de la pila de optimización

Modo	Funcional	Solver
Discreto	$\frac{1}{2}\ \mathbf{r}\ ^2$ con $r_i = (T - y_i)/\sigma_i$	<code>least_squares</code> (TRF, FD-Jac)
Distribución (Tikhonov)	$\ W^{1/2}(X\mathbf{z} - \mathbf{y})\ ^2 + \alpha\ L\mathbf{p}\ ^2$	<code>lsq_linear</code> (bounded, LSMR)
Distribución param.	$\ W^{1/2}(X(\boldsymbol{\eta})\mathbf{z} - \mathbf{y})\ ^2$	<code>least_squares</code> (NL, FD-Jac)
Refine global	$\ W^{1/2}(X(\boldsymbol{\eta})\hat{\mathbf{z}}(\boldsymbol{\eta}) - \mathbf{y})\ ^2$	ext. NL + int. acotado
L-curve	$\max_{\alpha} \kappa(\alpha)$ sobre 31 puntos	curvatura por diferencias

6. Conclusión

El motor de ajuste es funcionalmente correcto: combina un modelo físico de líneas Lorentzianas (o Voigt) con un solver de mínimos cuadrados acotados bien probado y diagnósticos estadísticos sólidos. Las mejoras propuestas se agrupan en tres familias: (a) **honestidad estadística** (Poisson, dof efectivos, barras en $P(B)$, propagación de $\sigma_{v_{\text{máx}}}$); (b) **calidad del óptimo** (VARPRO analítico, optimización global, warm-start, GCV); y (c) **fidelidad física** (3:2:1, Voigt analítico, Hamiltoniano completo, espesor). Cualquiera de las propuestas 4, 4, 4, 4 y 4 son cambios pequeños con beneficio inmediato. 4 y 4 son los más ambiciosos pero abren la aplicabilidad a muestras gruesas y a fases con interacción combinada fuerte.