

Manual matemático del motor de ajuste *Mossbauer*

Modelo directo, ajuste discreto y ajuste de distribución

Departamento de Química Física · UAM

5 de julio de 2026

Resumen

Este manual documenta, de forma autocontenida, la matemática completa del motor de ajuste de espectros Mössbauer de ^{57}Fe implementado en la aplicación. Cubre (i) el *modelo directo* —perfiles de línea, posiciones e intensidades de las seis líneas del sextete con tratamiento de primer orden y de Kündig del acoplamiento magnético-cuadrupolar, dobletes y singletes—; (ii) el *ajuste discreto* —estadística de los datos en modos Gauss y Poisson, propagación de la incertidumbre de calibración, funcional de coste con pérdidas robustas, optimización por región de confianza con arranque múltiple y opción global, covarianza, diagnósticos y bootstrap—; y (iii) el *ajuste de distribución* $P(B_{\text{hf}})$ o $P(\Delta E_Q)$ —discretización, núcleo, regularización de Tikhonov y de variación total, condicionamiento, grados de libertad efectivos, selección automática del parámetro de regularización, barras de error y distribuciones paramétricas. Se incluyen referencias a fichero y función del código.

Índice

Parte I

Modelo directo

1. Espectro de transmisión

Tras plegar los datos brutos en torno al punto de doblado, el espectro queda definido sobre N canales con velocidades $\{v_i\}$ y transmisión normalizada $\{y_i\}$, con $y_i \approx 1$ fuera de los picos de absorción. El modelo directo es una superposición lineal de absorciones sobre una línea base:

$$T(v; \boldsymbol{\theta}) = b + s v - \sum_{c=1}^{N_c} A_c(v; \boldsymbol{\theta}_c) \quad (1)$$

donde b es la línea base (multiplicativa, los datos están normalizados por el factor `norm_factor`), s la pendiente, y cada A_c es la absorción de un componente. Además de sextete, doblete y singlete, los componentes pueden ser modelos de **relajación magnética** (relajación fenomenológica, Blume–Tjon, Néel; véase el documento de relajación). Implementado en `core/physics.py`, función `total_model`.

Por defecto es un modelo de *absorbente delgado* (lineal en la profundidad). Opcionalmente se aplica un modelo de **absorbente grueso** con saturación, $T = b + s v - C(1 - e^{-A_{\text{tot}}/C})$ (parámetro $C = \text{sat_scale}$); el desarrollo está en el documento de corrección por espesor.

1.1. Forma de onda del drive y eje de velocidad

Con drive de **aceleración constante** (onda triangular) la velocidad es lineal con el canal: tras plegar, $\{v_i\}$ queda **equiespaciado** en $[-v_{\text{máx}}, v_{\text{máx}}]$ (`velocity_axis` en `core/folding.py`). Con drive **senoidal** la velocidad no es lineal; siguiendo el criterio de NORMOS (`TRIANG=.FALSE.`, `FOLD=.FALSE.`, `SIMULT=.TRUE.`) *no se pliega* y se asigna a cada canal su velocidad real

$$v_i = v_{\text{máx}} \sin\left(\frac{2\pi(i - c_0)}{N}\right), \quad (2)$$

con c_0 la fase (canal de $v = 0$), autodetectada por simetría y refinable como parámetro del ajuste. El eje resultante no es monótono, lo que el modelo tolera por evaluarse punto a punto (`sine_velocity_axis` en `core/folding.py`).

2. Perfiles de línea

Cada línea elemental usa un perfil normalizado a altura unidad en su centro. La aplicación ofrece dos perfiles, seleccionables globalmente.

2.1. Lorentziana

$$L(v; v_0, \gamma) = \frac{(\gamma/2)^2}{(v - v_0)^2 + (\gamma/2)^2}, \quad (3)$$

donde γ es el **parámetro de anchura que se ajusta**: la *anchura total a media altura* (FWHM). Por tanto la semianchura (HWHM) es $\gamma/2$, que es lo que aparece en la fórmula. Cumple $L(v_0) = 1$.

Convención de anchura

En el código y en la interfaz, el parámetro de anchura (γ_1 , etc.) es la **FWHM**. Internamente el perfil usa la semianchura $\gamma/2$ (`lorentzian` en `core/physics.py` divide entre dos antes de evaluar). Al leer γ como HWHM (versiones antiguas de este documento) las anchuras salían un factor 2 distintas.

2.2. Pseudo-Voigt (Faddeeva)

La convolución de una Lorentziana (HWHM $\gamma/2$) con una Gaussiana (anchura σ) es el perfil de Voigt, evaluado mediante la función de Faddeeva $w(z) = e^{-z^2} \text{erfc}(-iz)$:

$$\tilde{V}(v; v_0, \gamma, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \Re\left[w\left(\frac{(v - v_0) + i\gamma/2}{\sigma\sqrt{2}}\right)\right]. \quad (4)$$

Para que el perfil tenga altura exactamente 1 en v_0 *independientemente del muestreo*, se normaliza por su valor analítico en el pico:

$$V(v; v_0, \gamma, \sigma) = \frac{\tilde{V}(v; v_0, \gamma, \sigma)}{\tilde{V}(v_0; v_0, \gamma, \sigma)}, \quad \tilde{V}(v_0) = \frac{1}{\sigma\sqrt{2\pi}} \Re\left[w\left(\frac{i\gamma/2}{\sigma\sqrt{2}}\right)\right]. \quad (5)$$

Como $w(iy) = e^{y^2} \text{erfc}(y) \in \mathbb{R}^+$ para $y \in \mathbb{R}$, el denominador es real y positivo. En el límite $\sigma \rightarrow 0$, $V \rightarrow L$.

Normalización al pico

Normalizar por el máximo *discreto* de la malla (como hacían versiones previas) subestima el pico real cuando ningún v_i cae en v_0 , inflando la amplitud y haciendo que la profundidad dependa del muestreo. La forma (??) elimina ese sesgo.




Figura 1: Perfiles de línea normalizados a altura unidad y a igual FWHM. La Lorentziana (??) tiene *colas pesadas*; la Gaussiana decae mucho más deprisa; el pseudo-Voigt (??) interpola entre ambas. La escala logarítmica (derecha) hace visible el peso de las colas, que es lo que distingue a un perfil de otro lejos del centro.

3. Sextete magnético

Un sextete surge del desdoblamiento Zeeman nuclear combinado, en su caso, con la interacción cuadrupolar. Las seis líneas corresponden a las transiciones permitidas ($\Delta m = 0, \pm 1$) entre el estado fundamental $I_g = \frac{1}{2}$ y el excitado $I_e = \frac{3}{2}$. La absorción es

$$A_{\text{sext}}(v) = d \sum_{j=1}^6 W_j P(v; v_{0,j}, \gamma_j), \quad (6)$$

con d la profundidad, P el perfil (§??), W_j las intensidades (§??) y γ_j las anchuras

$$\gamma = \gamma_1 [1, \gamma_2, \gamma_3, \gamma_3, \gamma_2, 1], \quad (7)$$

donde γ_2, γ_3 son anchuras *relativas*. Las posiciones $v_{0,j}$ se obtienen por uno de dos tratamientos. La figura ?? resume el origen físico de las seis líneas.

3.1. Tratamiento de primer orden

El cuadrupolo se trata como una perturbación rígida sobre el patrón Zeeman:

$$v_{0,j} = \frac{B_{\text{hf}}}{B_0} r_j^{(0)} + \delta + s_j \Delta E_Q, \quad j = 1, \dots, 6, \quad (8)$$

con $B_0 = 33 \text{ T}$ el campo de referencia, δ el desplazamiento isomérico, $r^{(0)}$ las posiciones calibradas a B_0 (Apéndice ??) y el patrón cuadrupolar

$$\mathbf{s} = \left[+\frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, +\frac{1}{2} \right]. \quad (9)$$

Válido cuando $\Delta E_Q \ll \mu_N g_e B_{\text{hf}}$ y el eje del gradiente de campo eléctrico (EFG) es paralelo a $\vec{B}$.

3.2. Tratamiento de Kündig (Hamiltoniano completo axial)

Para EFG axial (parámetro de asimetría $\eta = 0$) y ángulo β arbitrario entre $\vec{B}$ y el eje principal V_{zz} , las posiciones se obtienen diagonalizando el Hamiltoniano del estado excitado. En la base $\{|\frac{3}{2}\rangle, |\frac{1}{2}\rangle, |-\frac{1}{2}\rangle, |-\frac{3}{2}\rangle\}$:

$$\mathcal{H}_e = \omega_e I_z + \frac{\Delta E_Q}{6} (3I_{z'}^2 - I(I+1)), \quad I_{z'} = I_z \cos \beta + I_x \sin \beta, \quad (10)$$




Figura 2: Origen del sexteto. El campo hiperfino desdobla por efecto Zeeman el nivel fundamental ($I_g = \frac{1}{2}$, dos subniveles) y el excitado ($I_e = \frac{3}{2}$, cuatro subniveles). Las seis transiciones permitidas ($\Delta m = 0, \pm 1$) producen las seis líneas, con intensidades 3 : 2 : 1 : 1 : 2 : 3 en polvo y posiciones a 33 T de $\pm 0,839 / \pm 3,084 / \pm 5,329$ mm/s. El cuadrupolo (no mostrado) desplaza rígidamente este patrón según (??).




Figura 3: Efecto del cuadrupolo en primer orden (??). Frente al sexteto puro ($\Delta E_Q = 0$, gris), un $\Delta E_Q \neq 0$ desplaza las líneas según el patrón $\mathbf{s} = [+ \frac{1}{2}, - \frac{1}{2}, - \frac{1}{2}, - \frac{1}{2}, - \frac{1}{2}, + \frac{1}{2}]$: las dos líneas externas se mueven en un sentido y las cuatro internas en el contrario, rompiendo la simetría del sexteto. La magnitud del desplazamiento mide ΔE_Q .

con $I(I+1) = \frac{15}{4}$ y $\omega_e = (B_{\text{hf}}/B_0)\omega_e^{(0)}$ el desdoblamiento Zeeman del excitado. La diagonalización numérica de la matriz 4×4 da los autovalores E_m^e y autovectores. El fundamental ($I_g = \frac{1}{2}$) es Zeeman puro:

$$E_{\pm 1/2}^g = \pm \frac{1}{2} \omega_g, \quad \omega_g = (B_{\text{hf}}/B_0)\omega_g^{(0)}. \quad (11)$$

Las seis posiciones son las diferencias de energía de las transiciones permitidas, asignando a cada autovalor del excitado su m_e dominante (por solapamiento del autovector):

$$\begin{aligned} v_{0,1} &= E_{-3/2}^e - E_{-1/2}^g, & v_{0,2} &= E_{-1/2}^e - E_{-1/2}^g, & v_{0,3} &= E_{+1/2}^e - E_{-1/2}^g, \\ v_{0,4} &= E_{-1/2}^e - E_{+1/2}^g, & v_{0,5} &= E_{+1/2}^e - E_{+1/2}^g, & v_{0,6} &= E_{+3/2}^e - E_{+1/2}^g, \end{aligned} \quad (12)$$

más δ . En el límite $\beta = 0$ reproduce (??) a precisión de máquina. Implementado en `core/hamiltonian.py`.

3.3. Promedio policristalino

En una muestra de polvo todas las orientaciones β son equiprobables. La absorción se promedia sobre la esfera:

$$A_{\text{sext}}^{\text{pol}}(v) = \frac{1}{2} \int_0^\pi \sin \beta A_{\text{sext}}(v; \beta) d\beta \approx \sum_{k=1}^{N_q} w_k A_{\text{sext}}(v; \beta_k), \quad (13)$$

con nodos y pesos de cuadratura de Gauss-Legendre sobre $x = \cos \beta \in [-1, 1]$, $\beta_k = \arccos x_k$, $w_k = \frac{1}{2} w_k^{\text{GL}}$ (de modo que $\sum_k w_k = 1$). El cálculo está vectorizado: para N_q orientaciones se construye y diagonaliza un tensor $(N_q, 4, 4)$ de una vez. Valor por defecto $N_q = 20$ (error $< 0,01\%$).




Figura 4: Promedio policristalino cuando $\Delta E_Q \neq 0$. En un monocrystal las posiciones de las seis líneas dependen del ángulo β entre $\vec{B}$ y el eje del EFG (curvas $\beta = 0^\circ$ y $\beta = 90^\circ$, calculadas con el Hamiltoniano de Küding (??)). En un polvo, todas las orientaciones coexisten: el espectro es la suma pesada (??) sobre β , que *ensancha* y *deforma* las líneas (curva superior). Por eso el tratamiento correcto de un sexteto cuadrupolar en polvo requiere promediar, no una sola orientación.

4. Intensidades y textura

Las intensidades de las seis líneas respetan la simetría $1 \leftrightarrow 6$, $2 \leftrightarrow 5$, $3 \leftrightarrow 4$:

$$\mathbf{W} = [I_1, I_2, I_3, I_3, I_2, I_1], \quad I_1 = i_3 i_1, \quad I_2 = i_3 i_2, \quad I_3 = i_3. \quad (14)$$

La aplicación ofrece dos parametrizaciones por sexteto.

4.1. Intensidades libres

i_1, i_2, i_3 son parámetros independientes del ajuste. No impone la relación 3:2:1; útil para flexibilidad numérica e interpretación empírica.

4.2. Parámetro de textura

Para una muestra con ángulo θ entre el momento magnético y la dirección del fotón γ , las amplitudes de dipolo magnético son

$$W_{1,6} \propto 3(1 + \cos^2 \theta), \quad W_{2,5} \propto 4 \sin^2 \theta, \quad W_{3,4} \propto (1 + \cos^2 \theta). \quad (15)$$

Definiendo el parámetro de textura $t = \sin^2 \theta \in [0, 1]$ y normalizando por $(1 + \cos^2 \theta) = 2 - t$:

$$\boxed{i_1 = 3, \quad i_2 = \frac{4t}{2-t}, \quad i_3 = 1.} \quad (16)$$

Casos: $t = \frac{2}{3} \Rightarrow 3:2:1$ (polvo aleatorio); $t = 1 \Rightarrow 3:4:1$ (textura plana, lámina $\perp$ haz); $t = 0 \Rightarrow 3:0:1$ (eje fácil $\parallel$ haz). En este modo t es el único parámetro libre de intensidad; i_1, i_2, i_3 se derivan de (??).




Figura 5: Textura del sexteto. *Izquierda*: la intensidad de las líneas centrales 2 y 5, $i_2 = 4t/(2-t)$ con $t = \sin^2 \theta$ (??), varía entre 0 (eje fácil paralelo al haz, 3:0:1) y 4 (lámina perpendicular, 3:4:1), pasando por el polvo aleatorio 3:2:1. *Derecha*: las tres situaciones sobre el mismo sexteto; las líneas 2 y 5 crecen con t mientras las demás no cambian.

5. Doblete y singlete

$$A_{\text{dob}}(v) = d \left[i_1 P(v; \delta - \frac{\Delta E_Q}{2}, \gamma_1) + i_1 i_2 P(v; \delta + \frac{\Delta E_Q}{2}, \gamma_1 \gamma_2) \right], \quad (17)$$

$$A_{\text{sing}}(v) = d i_1 P(v; \delta, \gamma_1). \quad (18)$$

Parte II

Ajuste discreto

6. Parametrización y restricciones

El vector de parámetros libres $\mathbf{x} \in \mathbb{R}^p$ se compone de los globales $\{b, s\}$ (más opcionalmente $v_{\text{máx}}$ y el centro de doblado c_{fold}) y, por cada componente activo, un subconjunto de $\boldsymbol{\theta}_c = (\delta, \Delta E_Q, B_{\text{hf}}, \gamma_1, \gamma_2, \gamma_3, d, i_1, i_2, i_3, t, \beta)$ según su tipo y modo:

- *Tipo*: singlete usa $\{\delta, \gamma_1, d, i_1\}$; doblete añade $\{\Delta E_Q, \gamma_2, i_2\}$; sextete usa todos.
- *Intensidades*: en modo textura, $\{i_1, i_2, i_3\}$ se sustituyen por el único parámetro t .
- *Cuadrupolo*: en modo Kündig con β fijo, β entra como parámetro libre; en modo policristal o primer orden, no.
- *Fijos*: parámetros marcados se retiran del vector activo.
- *Restringidos lineales* $k_t = \alpha k_s + \beta_0$: se aplican en cada evaluación (hasta seis iteraciones para cadenas de dependencias).

Cada parámetro tiene cotas duras $[\ell_k, u_k]$ (Apéndice ??).

7. Estadística de los datos

7.1. Modo Gauss

El doblado promedia dos canales Poisson independientes; para conteos c_i por canal plegado, $\text{Var} \approx c_i/2$, de donde la incertidumbre 1σ del dato normalizado:

$$\sigma_i = \frac{\max(\sqrt{c_i/2}, 1)}{f_{\text{norm}}}, \quad \sigma_i \leftarrow \max(\sigma_i, 10^{-9}). \quad (19)$$

7.2. Modo Poisson (IRLS)

La verosimilitud Poisson se aproxima por mínimos cuadrados reponderados: la incertidumbre se evalúa sobre el *modelo* (cuentas predichas $\hat{c}_i = T_i f_{\text{norm}}$) y se recalcula en cada evaluación del optimizador, lo que equivale a un paso de Newton sobre $-2 \log \mathcal{L}$ Poisson:

$$\sigma_i^{\text{Pois}} = \frac{\sqrt{\max(\hat{c}_i/2, 1)}}{f_{\text{norm}}} = \frac{\sqrt{\max(T_i f_{\text{norm}}/2, 1)}}{f_{\text{norm}}}. \quad (20)$$

7.3. Propagación de la incertidumbre de calibración

Si la calibración de velocidad aporta una incertidumbre $\sigma_{v_{\text{máx}}}$, su efecto sobre el modelo se suma en cuadratura. Como $v_i = v_{\text{máx}}(2i/(N-1) - 1)$, se tiene $\partial v_i / \partial v_{\text{máx}} = v_i / v_{\text{máx}}$, y por la regla de la cadena

$$\sigma_i^{\text{eff}2} = \sigma_i^2 + \left(\frac{\partial T}{\partial v} \bigg|_i \frac{v_i}{v_{\text{máx}}} \sigma_{v_{\text{máx}}} \right)^2. \quad (21)$$

El término pesa más en los flancos de los picos (donde $\partial T / \partial v$ es grande), que es donde un error de escala sesga δ y B_{hf} .

8. Funcional de coste y pérdidas robustas

El residuo ponderado es

$$r_i(\mathbf{x}) = \frac{T(v_i; \mathbf{x}) - y_i}{\sigma_i^{\text{eff}}}, \quad (22)$$

y el funcional minimizado

$$\mathcal{C}(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^N \rho(r_i(\mathbf{x})^2), \quad (23)$$

con ρ la función de pérdida: *lineal* $\rho(z) = z$ (mínimos cuadrados), *soft- ℓ_1* $\rho(z) = 2(\sqrt{1+z} - 1)$, o *Huber*. Las robustas usan escala $f_{\text{scale}} = 3$ (umbral $\sim 3\sigma$), reduciendo el peso de canales con picos espurios. Para ρ lineal, $\mathcal{C} = \frac{1}{2}\chi^2$. La figura ?? compara las pérdidas y el peso que asigna cada una.




Figura 6: Pérdidas robustas frente a mínimos cuadrados. *Izquierda*: la pérdida lineal (χ^2) crece como r^2 , mientras *soft- ℓ_1* y Huber crecen *linealmente* para residuos grandes. *Derecha*: el peso efectivo (reponderación IRLS) es constante para la lineal, pero decae con $|r|$ en las robustas, de modo que un canal atípico (pico espurio, rayo cósmico) influye mucho menos en el ajuste.

9. Optimización

9.1. Región de confianza (TRF)

Se minimiza con *Trust Region Reflective* sobre las cotas:

$$\hat{\mathbf{x}} = \arg \min_{\ell \leq \mathbf{x} \leq \mathbf{u}} \mathcal{C}(\mathbf{x}), \quad (24)$$

resolviendo en cada iteración el subproblema cuadrático con Jacobiano por diferencias finitas:

$$\min_{\mathbf{d}} \frac{1}{2} \|J_k \mathbf{d} + \mathbf{r}_k\|^2 \quad \text{s.a.} \quad \|\mathbf{D}_k \mathbf{d}\| \leq \Delta_k, \quad \ell - \mathbf{x}_k \leq \mathbf{d} \leq \mathbf{u} - \mathbf{x}_k. \quad (25)$$

9.2. Arranque múltiple

Se prueban el punto del usuario más 8 reinicios gaussianos:

$$\mathbf{x}^{(s)} = \mathbf{x}^{(0)} + \boldsymbol{\xi}^{(s)}, \quad \xi_k^{(s)} \sim \mathcal{N}(0, \rho_k^2 (u_k - \ell_k)^2), \quad (26)$$

con $\rho_k = 0,12$ para $\{\delta, \Delta E_Q, B_{\text{hf}}, \gamma_1, d, v_{\text{máx}}\}$ y 0,08 en el resto; semilla fija. Se retiene el de menor coste.




Figura 7: Arranque múltiple. El coste puede tener mínimos locales además del global. Partir de varios puntos iniciales y quedarse con el de menor coste reduce el riesgo de converger a un mínimo local: en el ejemplo, solo el arranque central alcanza el mínimo global.

9.3. Optimización global (opcional)

Como pre-pasada opcional se ejecuta *differential evolution* sobre el coste escalar $\frac{1}{2}\|\mathbf{r}\|^2$ (inicialización Sobol, sin pulido), y su mejor punto se añade como semilla para el pulido TRF. Cubre mínimos locales por permutación de etiquetas e intercambios $B_{\text{hf}}^{(1)} \leftrightarrow B_{\text{hf}}^{(2)}$ en espectros multi-sextete que el arranque gaussiano no alcanza.

10. Incertidumbres y diagnósticos

10.1. Covarianza

A partir del Jacobiano final $J = U\Sigma V^\top$ (SVD, valores singulares truncados):

$$\widehat{\text{Cov}}(\hat{\mathbf{x}}) = V \Sigma^{-2} V^\top \cdot \frac{2\mathcal{C}(\hat{\mathbf{x}})}{N-p}, \quad \hat{\sigma}_{x_k} = \sqrt{\widehat{\text{Cov}}_{kk}}. \quad (27)$$

Se reportan correlaciones $|\rho_{kl}| \geq 0,95$ como aviso de degeneración.

10.2. Estadísticos de bondad de ajuste

$$\chi^2 = \sum_i r_i^2, \quad \nu = N - p, \quad \chi_\nu^2 = \chi^2/\nu, \quad (28)$$

$$\text{AIC} = N \ln(\text{RSS}/N) + 2p, \quad \text{BIC} = N \ln(\text{RSS}/N) + p \ln N. \quad (29)$$




Figura 8: Covarianza frente a verosimilitud perfilada. La covarianza (??) aproxima el pozo de χ^2 por una parábola y da un error *simétrico*. La verosimilitud perfilada recorre el parámetro reajustando los demás y mide el χ^2 real; el corte $\Delta\chi^2 = 1$ da un intervalo de confianza *asimétrico*, más realista cuando el pozo no es parabólico.

10.3. Diagnósticos del residuo

Para detectar estructura no aleatoria (con $\tilde{r} = r - \bar{r}$):

$$\text{autocorrelación lag-1: } \rho_1 = \frac{\sum_i \tilde{r}_i \tilde{r}_{i+1}}{\sum_i \tilde{r}_i^2}, \quad (30)$$

$$\text{rachas (Wald-Wolfowitz): } Z = \frac{R - \mu_R}{\sigma_R}, \quad (31)$$

$$\text{correlación antisimétrica: } c_{\text{as}} = \frac{\tilde{\mathbf{r}} \cdot (-\tilde{\mathbf{r}}^{\text{rev}})}{\tilde{\mathbf{r}} \cdot \tilde{\mathbf{r}}}, \quad (32)$$

con avisos si $|\rho_1| > 0,35$, $|Z| > 2$ o $c_{\text{as}} > 0,45$ (esta última detecta errores de centrado/calibración).

10.4. Bootstrap

Estimación Monte Carlo de errores: M réplicas de datos sintéticos $\tilde{y}^{(m)} = T(\cdot; \hat{\mathbf{x}}) + \eta^{(m)}$, con $\eta^{(m)}$ gaussiano de desviación σ_i (o remuestreo Poisson real $\tilde{c} \sim \text{Poisson}(\hat{c})$ en modo Poisson); se reajusta cada réplica y $\hat{\sigma}_{x_k}^{\text{boot}} = \text{std}_m(\hat{x}_k^{(m)})$.

Parte III

Ajuste de distribución

11. Discretización y núcleo

Se modela el espectro como una densidad continua $P(B_{\text{hf}})$ (o $P(\Delta E_Q)$) discretizada en n bins de centros equiespaciados $c_k \in [p_{\text{mín}}, p_{\text{máx}}]$. El *núcleo*

$$K_{ik} = A_{\text{sext}}^{(d=1)}(v_i; B_{\text{hf}} = c_k) \quad (33)$$

es la absorción a v_i de un sextete de profundidad unitaria con campo c_k (variable B_{hf}) o con $\Delta E_Q = c_k$ y B_{hf} fijo (variable ΔE_Q). Las intensidades del núcleo siguen 3:2:1 por construcción.

12. Sistema lineal aumentado

El forward es

$$\hat{y}_i = b + s v_i - \sum_k K_{ik} P_k - \sum_m K_{im}^{\text{sharp}} q_m, \quad (34)$$

con $P_k \geq 0$ los pesos de la distribución y $q_m \geq 0$ amplitudes de sextetes “nítidos” opcionales. Definiendo la matriz de diseño

$$X = [\mathbf{1} \mid \mathbf{v} \mid -K \mid -K^{\text{sharp}}], \quad \mathbf{z} = (b, s, \mathbf{P}^\top, \mathbf{q}^\top)^\top, \quad (35)$$

y los pesos $W = \text{diag}(1/\sigma_i^2)$, el problema es

$$\min_{\mathbf{z}} \|W^{1/2}(X\mathbf{z} - \mathbf{y})\|_2^2 + \alpha \mathcal{R}(\mathbf{P}) \quad \text{s.a.} \quad b \geq 0, \mathbf{P} \geq 0, \mathbf{q} \geq 0. \quad (36)$$

La pendiente s no tiene cota. Se resuelve con mínimos cuadrados acotados (`lsq_linear`, `reflective Newton` con `LSMR`).

12.1. Preacondicionamiento por escala de columnas

Para B_{hf} pequeño el sextete colapsa y las columnas de K se vuelven casi colineales con normas muy dispares, lo que mal-condiciona (??). Se reescala cada columna de la distribución $K_k \rightarrow K_k/s_k$ con $s_k = \|W^{1/2}K_k\|$ y $\tilde{P}_k = s_k P_k$; el penalizador y los pesos se ajustan en consecuencia y se deshace la escala al final. Es una reparametrización *exacta* (solución y grados de libertad invariantes) que sólo mejora la estabilidad numérica.

13. Regularización

El problema inverso está *mal condicionado*: muchas $\mathbf{P}$ distintas reproducen casi igual el espectro. Añadir un término $\alpha \mathcal{R}(\mathbf{P})$ selecciona una solución estable. El valor de α es el compromiso entre fidelidad y suavidad; la figura ?? muestra los tres regímenes.




Figura 9: Efecto del parámetro de regularización α sobre la distribución recuperada de un mismo espectro. Con α demasiado pequeño (sub-regularizado) aparecen *oscilaciones espurias* que ajustan el ruido; con α demasiado grande (sobre-regularizado) la estructura real se *lava*; el valor de la esquina de la L-curve (véase el capítulo de distribuciones del manual de usuario) mantiene el equilibrio. En gris, la distribución verdadera.

13.1. Tikhonov (suavidad, L2)

$\mathcal{R}(\mathbf{P}) = \|\mathbf{L}\mathbf{P}\|_2^2$ con $\mathbf{L}$ el operador de *segunda diferencia* $(n-2) \times n$:

$$(\mathbf{L}\mathbf{P})_k = P_{k-1} - 2P_k + P_{k+1}, \quad (37)$$

que penaliza la curvatura y produce distribuciones suaves. El sistema aumentado apila $\begin{bmatrix} W^{1/2}X \\ \sqrt{\alpha}L_{\text{ext}} \end{bmatrix} \mathbf{z} = \begin{bmatrix} W^{1/2}\mathbf{y} \\ \mathbf{0} \end{bmatrix}$.

13.2. Variación total (bordes, L1)

$\mathcal{R}(\mathbf{P}) = \|\mathbf{D}\mathbf{P}\|_1$ con $\mathbf{D}$ la *primera diferencia* $(\mathbf{D}\mathbf{P})_k = P_{k+1} - P_k$. Favorece soluciones constantes-a-trozos que preservan bordes (menos emborronamiento de picos). Se resuelve por mínimos cuadrados reponderados (IRLS): partiendo de la mayorización $|t| \leq t^2/(2|t^{\text{prev}}|) + \text{cte}$, cada iteración resuelve un Tikhonov ponderado con

$$w_k = \frac{1}{\sqrt{(\mathbf{D}\mathbf{P}^{\text{prev}})_k^2 + \varepsilon^2}}, \quad \mathcal{R} \approx \sum_k w_k (\mathbf{D}\mathbf{P})_k^2, \quad (38)$$

reutilizando `lsq_linear`. El operador efectivo $\sqrt{w}\mathbf{D}$ se emplea también para los grados de libertad y las barras de error.

13.3. Máxima entropía (MaxEnt)

Tercera opción de `reg_mode`. En vez de penalizar la curvatura o los bordes, maximiza la *entropía* de la distribución (la solución más «uniforme» compatible con los datos, sin introducir estructura no justificada):

$$\min_{\mathbf{z}} \frac{1}{2} \|\mathbf{y} - \mathbf{X}\mathbf{z}\|_2^2 - \alpha S(\mathbf{P}), \quad S(\mathbf{P}) = - \sum_k P_k \log \frac{P_k}{m_k}, \quad (39)$$

con m_k un modelo por defecto (uniforme). Como la entropía **no es cuadrática**, no puede usarse `lsq_linear`: se optimiza con **L-BFGS-B** y gradiente analítico sobre las variables físicas $\mathbf{z} = [b, s, \mathbf{P}, \mathbf{q}]$ (`_solve_maxent` en `mossbauer_distribution.py`). Los grados de libertad efectivos usan la Hessiana correspondiente a este funcional.

14. Verosimilitud Poisson en la distribución

En modo Poisson el ajuste de histograma se repite con reponderado IRLS de la σ a partir del modelo (§??), cerrando el lazo a través de `lsq_linear` hasta convergencia.

15. Grados de libertad efectivos

La regularización reduce los grados de libertad por debajo de n . El número efectivo es la traza de la matriz sombrero:

$$p_{\text{eff}} = \text{tr } A(\alpha), \quad A(\alpha) = \mathbf{X}(\mathbf{X}^\top \mathbf{W} \mathbf{X} + \alpha \mathbf{L}^\top \mathbf{L})^{-1} \mathbf{X}^\top \mathbf{W}, \quad (40)$$

calculable como $\text{tr}[(\mathbf{X}^\top \mathbf{W} \mathbf{X} + \alpha \mathbf{L}^\top \mathbf{L})^{-1} \mathbf{X}^\top \mathbf{W} \mathbf{X}]$. Se usa en $\chi_\nu^2 = \chi^2/(N - p_{\text{eff}})$, evitando el sesgo de contar los n bins como parámetros independientes. Es invariante bajo el reescalado de columnas de §??.

16. Selección del parámetro de regularización

16.1. α adimensional

El α que fija el usuario **no** es el peso bruto de (??). El término de datos es un $\chi^2 \sim N$, pero el penalizador va en unidades de absorción; sin normalizar, el α «útil» dependería de N , del ruido σ y de la profundidad de absorción, y el mismo número significaría cosas distintas en cada espectro. Por eso el α de la interfaz se **adimensionaliza** antes de aplicarlo:

$$\alpha_{\text{eff}} = \alpha \lambda_{\text{ref}} c_0, \quad \lambda_{\text{ref}} = \frac{\|A_{\text{dist}}\|_F^2}{\|L_{\text{scaled}}\|_F^2}, \quad c_0 = 10^{-4}, \quad (41)$$

donde A_{dist} y L_{scaled} son la parte de distribución de $W^{1/2}X$ y el penalizador *blanqueados* (tras el reescalado de columnas de §??), $\|\cdot\|_F$ la norma de Frobenius y $c_0 = \text{ALPHA_REF_SCALE}$. El sistema aumentado usa $\sqrt{\alpha_{\text{eff}}}L$ en lugar de $\sqrt{\alpha}L$; lo mismo p_{eff} (??) y las barras de error. El efecto: $\log_{10} \alpha \approx 0$ es el **equilibrio natural** datos/suavidad para *cualquier* espectro, y el codo de la curva L queda estable frente a N , ruido y profundidad (valores útiles típicos $-1 \dots +2$). En 2D se hace lo mismo por cada eje (α_B , α_Q) con su λ_{ref} propio.

Sobre una malla logarítmica de α se calculan tres criterios.

Curva L (máxima curvatura). Con $\rho(\alpha) = \log\|W^{1/2}(X\hat{z} - y)\|$ y $\eta(\alpha) = \log\|L\hat{P}\|$, la esquina maximiza

$$\kappa(\alpha) = \frac{\rho'\eta'' - \eta'\rho''}{((\rho')^2 + (\eta')^2)^{3/2}}. \quad (42)$$

Compromiso. Mínima distancia normalizada al origen en el plano (η, ρ) .

Validación cruzada generalizada (GCV).

$$\text{GCV}(\alpha) = \frac{\|W^{1/2}(\mathbf{y} - X\hat{z})\|^2}{(N - p_{\text{eff}}(\alpha))^2}, \quad \hat{\alpha} = \arg \min_{\alpha} \text{GCV}(\alpha), \quad (43)$$

que no requiere conocer la escala del ruido y es óptima en pérdida de predicción.

17. Barras de error de $P(B_{\text{hf}})$

Para el estimador regularizado $\hat{z} = H^{-1}X^{\top}W\mathbf{y}$ con $H = X^{\top}WX + \alpha L^{\top}L$, la covarianza linealizada es

$$\widehat{\text{Cov}}(\hat{z}) = H^{-1}(X^{\top}WX)H^{-1} \cdot \frac{\chi^2}{N - p_{\text{eff}}}, \quad (44)$$

escalada por el χ^2_{ν} efectivo (igual convención que el ajuste discreto). La raíz de la diagonal correspondiente a los bins da σ_{P_k} . La banda $P_k \pm \sigma_{P_k}$ se recorta a $P \geq 0$ al representarla (la no-negatividad la hace asimétrica en bins clavados a cero). En modo TV se usa el operador efectivo $\sqrt{w}D$ en lugar de L .

18. Distribuciones paramétricas

Como alternativa al histograma regularizado, se ajustan formas cerradas con pocos parámetros (mínimos cuadrados no lineales, sin α):

$$\text{Gaussiana: } P_k \propto \exp\left(-\frac{1}{2}\left((c_k - \mu)/\varsigma\right)^2\right), \quad (b, s, A, \mu, \log \varsigma), \quad (45)$$

$$\text{VBF: } P_k = \sum_{j=1}^N A_j \mathcal{N}(c_k; \mu_j, \sigma_j), \quad (b, s, \{A_j, \mu_j, \log \sigma_j\}_{j=1}^N), \quad (46)$$

$$\text{Binomial: } P_k \propto \binom{n-1}{k-1} p^{k-1} (1-p)^{n-k}, \quad (b, s, A, \text{logit } p), \quad (47)$$

$$\text{Fija: } P_k = \phi_k \text{ (precargada)}, \quad (b, s, A). \quad (48)$$

VBF (Voigt-Based Fitting, Rancourt–Ping 1991). Generaliza la Gaussiana a una suma de N gaussianas ($N = 1 \dots 6$) sobre un núcleo Voigt, cada una con amplitud A_j , media μ_j y anchura σ_j (guardadas ordenadas por μ). Como el núcleo gaussiano $\mathcal{N}$ está **normalizado a área unidad**, el coeficiente A_j es el **área** de esa componente sobre la malla; su fracción $A_j / \sum_i A_i$ da la **población** de cada entorno, que Fitbauer reporta como «área %». Admite las pendientes de correlación de §??.




Figura 10: VBF (Rancourt–Ping). La distribución se modela como suma de gaussianas; como el núcleo está normalizado a área unidad, la amplitud A_j de cada componente es su área y su fracción $A_j / \sum_i A_i$ da la población del entorno. La suma (negro) reproduce la $P(B_{\text{hf}})$ con pocos parámetros y sin regularización.

19. Correlación $\delta(H)$ y $\Delta E_Q(H)$ en el núcleo

Por defecto todos los subespectros del núcleo comparten el mismo δ y ΔE_Q , y solo varía el campo. Opcionalmente se acoplan δ y ΔE_Q al campo del bin mediante dos pendientes (modelo de Le Caër–Dubois / Wivel–Mørup):

$$\delta_k = \delta_0 + \kappa_\delta (c_k - H_{\text{ref}}), \quad \Delta E_{Q,k} = \Delta E_{Q,0} + \kappa_q (c_k - H_{\text{ref}}), \quad (49)$$

con H_{ref} un campo de referencia. Así el núcleo K_{ik} se construye usando $(\delta_k, \Delta E_{Q,k})$ en cada columna en vez de valores globales. Con $\kappa_\delta = \kappa_q = 0$ se recupera el caso clásico. Las pendientes se refinan en el bucle externo (§??) y aplican al Histograma y al VBF.

20. Refinamiento global (VARPRO)

Cuando se activa, un bucle externo no lineal optimiza los parámetros de forma $\boldsymbol{\eta} = (\delta_g, \log \gamma_g, \dots)$; en cada evaluación se resuelve *íntegramente* el problema lineal interno (??), devolviendo el residuo al optimizador (esquema separable tipo VARPRO):

$$\min_{\boldsymbol{\eta}} \|W^{1/2}[X(\boldsymbol{\eta}) \hat{\mathbf{z}}(\boldsymbol{\eta}) - \mathbf{y}]\|^2, \quad \hat{\mathbf{z}}(\boldsymbol{\eta}) = \arg \min_{\mathbf{z}} (??). \quad (50)$$

Parte IV

Apéndices

A. Calibración del sextete

Las posiciones de referencia a $B_0 = 33,0$ T son las **publicadas** de α -Fe (patrón de velocidad estándar), sin factor de reescala adicional:

$$r^{(0)} = \frac{1}{2}[-10,657, -6,167, -1,677, 1,677, 6,167, 10,657] = [\mp 5,3285, \mp 3,0835, \mp 0,8385] \text{ mm/s}. \quad (51)$$

Las posiciones para un campo B_{hf} escalan linealmente, $r^{(0)} \cdot (B_{\text{hf}}/33,0)$. De ellas se derivan los desdoblamientos Zeeman usados en (??):

$$\omega_e^{(0)} = r_2^{(0)} - r_1^{(0)} \approx 2,245 \text{ mm/s}, \quad \omega_g^{(0)} = -[(r_4^{(0)} - r_3^{(0)}) + \omega_e^{(0)}] \approx -3,922 \text{ mm/s}. \quad (52)$$

Sin factor 32.95

Versiónes previas de este documento incluían un factor ($B_0/32,95$) que sobreescalaba las posiciones $\sim 0,15\%$. El código usa las posiciones publicadas *tal cual* (`LINE_POS_33T` en `core/constants.py`), por lo que ese factor se ha eliminado (y con él $\omega_e^{(0)}$, $\omega_g^{(0)}$ pasan de 2,248/−3,928 a 2,245/−3,922).

B. Cotas de los parámetros

Parámetro	Cota	Unidad
b (línea base)	[0,7, 1,3]	—
s (pendiente)	$[-5 \cdot 10^{-3}, 5 \cdot 10^{-3}]$	mm^{-1}s
δ	[-2, 3]	mm/s
ΔE_Q	[-4, 4]	mm/s
B_{hf}	[0, 60]	T
γ_1 (FWHM)	[0,06, 4]	mm/s
γ_2, γ_3	[0,2, 6]	(relativa)
d (profundidad)	[0, 0,30]	—
i_1, i_2, i_3	$[0,9]/[0,6]/[0,3]$	(relativa)
t (textura)	[0, 1]	—
β	[0, 90]	grados

C. Función de Faddeeva

$w(z) = e^{-z^2} \text{erfc}(-iz)$, evaluada por `scipy.special.wofz`. La parte real da el perfil de Voigt (??); para $z = iy$ con $y \in \mathbb{R}$, $w(iy) = e^{y^2} \text{erfc}(y)$ es real, lo que permite la normalización analítica al pico.

D. Resumen de la pila de optimización

Modo	Funcional	Solver
Discreto	$\frac{1}{2} \sum_i \rho(r_i^2)$	<code>least_squares</code> (TRF) [+ DE opcional]
Distribución Tikhonov	$\ W^{1/2}(X\mathbf{z} - \mathbf{y})\ ^2 + \alpha\ L\mathbf{P}\ ^2$	<code>lsq_linear</code> (acotado)
Distribución TV	$\ W^{1/2}(X\mathbf{z} - \mathbf{y})\ ^2 + \alpha\ D\mathbf{P}\ _1$	IRLS sobre <code>lsq_linear</code>
Distribución paramétrica	$\ W^{1/2}(X(\boldsymbol{\theta})\mathbf{z} - \mathbf{y})\ ^2$	<code>least_squares</code> (NL)
Refinamiento global	$\ W^{1/2}(X(\boldsymbol{\eta})\hat{\mathbf{z}}(\boldsymbol{\eta}) - \mathbf{y})\ ^2$	externo NL + interno acotado